

# Curso: Engenharia de Computação

Linguagens Formais e Compiladores

Prof. Clayton J A Silva, MSc

clayton.silva@professores.ibmec.edu.br



# BNF e análise léxica

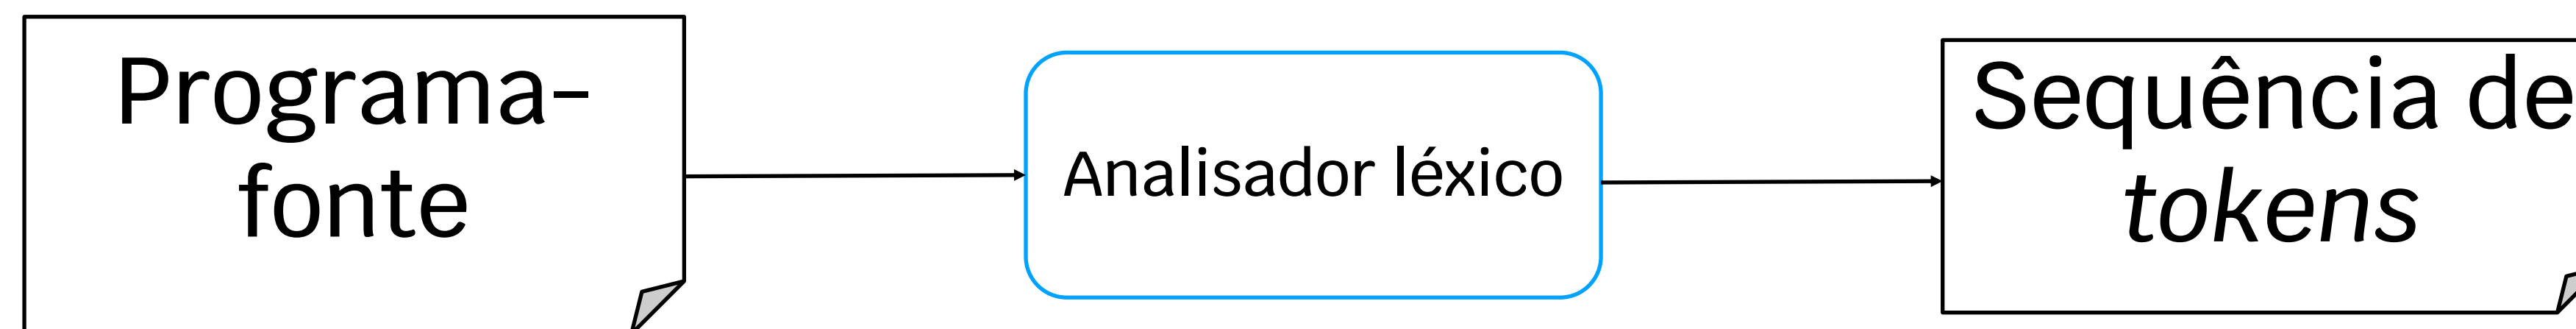
- A definição da linguagem deve determinar a interpretação a ser observada na análise – deve fornecer, por exemplo, as regras de eliminação de ambiguidade
- A descrição da sintaxe da linguagem pode ser realizada utilizando-se a forma de Backus-Naur ou BNF
- A perspectiva que discutiremos se baseia nas premissas: **existe a descrição sintática da linguagem, existe um código escrito por um programador** – como analisar se o código respeita a sintaxe?

# Varredura ou análise léxica

---

# Varredura ou análise léxica

- É a fase de um compilador que lê o arquivo de um programa-fonte como um arquivo de caracteres e o converte em uma sequência de *tokens*.



# Varredura ou análise léxica

- Genericamente, os *tokens* podem ser palavras reservadas ou palavras-chave, identificadores, símbolos especiais e literais ou constantes
- Os *tokens* classificam os *lexemas*; existem *tokens* que podem classificar somente um lexema; existem *tokens* que podem classificar infinitos lexemas
- Qualquer **valor** associado a um *token* recebe o nome de um **atributo** do *token*
- O sistema de varredura poderá definir vários atributos a cada *token* quanto necessários para prosseguir o processamento

# Varredura ou análise léxica


- O conjunto de atributos de um token pode ser atribuído a uma estrutura de dados chamada **registro** do token

```
struct  
{ TokenType tokenval;  
  tipo atributo1token;  
  ...  
}
```

- O analisador sintático – que controla a análise léxica – normalmente chama o *token* por uma **função**, que **retorna o próximo *token* identificado no código**

# Varredura ou análise léxica

- O processo para desenvolver o programa de varredura (análise léxica) geralmente consiste em aplicar **métodos de especificação e de reconhecimento de padrões: expressões regulares e autômatos finitos.**



# Varredura ou análise léxica

- As expressões regulares constituem uma **notação padrão para representar padrões em cadeias de caracteres** que formam a estrutura léxica de uma LP
- As máquinas de estados finitos, ou autômatos finitos, são **algoritmos para reconhecimento de padrões** em cadeias de caracteres dadas por expressões regulares.



# Expressões regulares

- Representam padrões de cadeias de caracteres
- Uma expressão  $r$  é definida pelo conjunto de cadeias de caracteres com as quais ela casa, chamado de linguagem gerada pela expressão regular
- A expressão é definida por:  $L(r) = \Omega$ , onde  $\Omega$  é o conjunto de cadeias de caracteres definido entre chaves
- Uma expressão regular  $r$  pode conter caracteres com significados especiais, chamados de metacaracteres ou meta-símbolos

# Expressões regulares básicas

1. Caracteres em separado do alfabeto ( $\Sigma$ ), que casam com eles mesmos. Indica-se  $L(a) = \{a\}$ , onde  $a$  é a expressão regular e  $a$  é o símbolo do alfabeto.
  2. Cadeia vazia, ou seja, a cadeia sem caracteres, designada  $\varepsilon$ . Indica-se  $L(\varepsilon) = \{\varepsilon\}$ .
- **Conjunto vazio**, aquele para o símbolo que não casa com nenhuma cadeia de caracteres. Indica-se  $L(\Phi) = \{ \}$

# Operações de expressões regulares

- (1) Escolha entre alternativas, representada pelo meta-símbolo  $|$
- (2) Concatenação, representada pela justaposição – sem meta-símbolos
- (3) Repetição ou fecho, representada pelo meta-símbolo  $*$

# Escolha entre alternativas (I)

- Se  $r$  e  $s$  são expressões regulares, então  $r/s$  é uma expressão regular que casa com qualquer cadeia que casa com  $r$  ou casa com  $s$ .
- A operação pode ser definida por:  $L(r/s) = L(r) \cup L(s)$
- Aplica-se a escolha com a cadeia vazia:  $L(r/\varepsilon) = \{r, \varepsilon\}$

# Concatenação

- Se  $r$  e  $s$  são expressões regulares, então  $rs$  é uma expressão regular que casa com qualquer cadeia que casa com  $r$  concatenado com  $s$ .
- A operação pode ser definida por:  $L(rs) = L(r)L(s)$

# Repetição ou fecho ( $*$ )

- Se  $r$  é expressão regular, então  $r^*$  é uma expressão regular que casa com qualquer concatenação finita de cadeias de caracteres, desde que cada cadeia case com  $r$ .
- A operação pode ser definida por  $L(r^*) = L(r)^*$

# Precedências e parênteses

- Precedência: 1. repetição, 2. concatenação, 3. escolha
- A precedência entre expressões regulares pode ser definida pelo uso de parênteses
- Nomes para expressões regulares: são usados para simplificar expressões longas – o nome é um meta-símbolo



# Extensões de expressões regulares

- **Uma ou mais repetições** – sem 0 repetição – Seja  $r$  uma expressão regular,  $r^+$  representa uma ou mais repetições
- **Casamento com qualquer caractere do alfabeto** – Seja  $r$  uma expressão regular,  $r.$  representa que  $r$  pode ser concatenada com qualquer caractere
- **Intervalo de caracteres** – Pode-se usar colchetes e um hífen – a notação deve depender da ordenação do conjunto de caracteres a representar



# Extensões de expressões regulares

- **Caractere fora de um conjunto** – Pode-se utilizar um meta-símbolo para indicar um ‘não’ ou complemento. Um meta-símbolo usado é o  $\sim$ .
- **Partes opcionais** – Pode-se utilizar a parte opcional como um caractere que concatena com a expressão regular. Para evidenciar que são opcionais, utiliza-se o meta-símbolo  $?$  após a parte opcional

# Expressões regulares típicas para *tokens*

- **Números.** Podem ser apenas sequências de dígitos (números naturais), números decimais ou números com um expoente

$nat = [0-9]^+$

$sinalNat = (+|-)? nat$

$numero = sinalNat (.nat)? (E sinalNat)?$

# Expressões regulares típicas para *tokens*

- Palavras reservadas e identificadores.

*reservadas = if | while | do | for | ...*

*letra = [a-z A-Z]*

*digito = [0-9]*

*identificador = letra(letra | digito)\**

# Expressões regulares típicas para *tokens*

- **Comentários.** Normalmente ignorados durante a varredura, que precisa identificá-los e descartá-los.

# Referências

- Louden, Kenneth C.; Compiladores princípios e práticas; Capítulos 2.1 e 2.2; THOMSON



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC\_OFICIAL

 @IBMEC

 **ibmec**